## Tarea 2

Profesor: Felipe Tobar

Auxiliares: Mauricio Araneda, Alejandro Cuevas, Mauricio Romero

**Consultas:** Alejandro Cuevas **Fecha entrega:** 2/5/2019

**Formato entrega:** Entregue un informe en formato PDF con una extensión de a lo más **3** páginas presentando y analizando sus resultados, detalle la metodología utilizada y adicionalmente debe entregar un jupyter notebook con los códigos que creó para resolver la tarea.

## P1. Regresión No Lineal

Se tienen los datos de la cantidad de pasajeros de una aerolínea medidos de forma mensual. Los datos son de la forma  $\{(x_i,y_i)\}_{i=1}^N$  donde  $x_i$  representa un mes,  $y_i$  la cantidad de pasajeros transportados en el mes correspondiente. Los datos los puede encontrar en:

https://github.com/GAMES-UChile/Curso-Aprendizaje-de-Maquinas/blob/master/datos/datosT2.txt

El objetivo de esta tarea es modelar la cantidad de pasajeros (y) respecto al instante de tiempo (x), para este fin, se asumirá el siguiente modelo:

$$y = f_{\theta}(x) + \eta$$

Donde  $\theta$  corresponde a los parámetros de la función f, y  $\eta \sim \mathcal{N}(0, \sigma_{\eta}^2)$  corresponde a ruido gaussiano. Luego, los parametros a ajustar se denotan:

$$\theta' = [\theta, \sigma_{\eta}^2]$$

Para las parte que siguen, considere 75% de los datos (los primeros 9 años) para entrenamiento de su modelo y el 25% restante para validar sus resultados, para esto deberá:

- (i) Cargue los datos **datos T2.txt** y grafíquelos de forma que se pueda distinguir entre el conjunto de entrenamiento y test.
- (ii) Modele  $f_{\theta}$  como un polinomio, es decir:

$$f_{\theta}(x) = \theta_0 + \theta_1 x + \theta_2 x^2 + \dots$$

Considere un prior Gaussiano sobre los parámetros  $\theta'$  y encuentre dichos parámetros usando el método *máximo* a posteriori.

En base a los resultados obtenidos indique y discuta cual es el grado del polinomio que es más probable que haya generado los datos.

**HINT:** Considere polinomios entre grado 1 y 4.

(iii) Como podrá observar el modelo polinomial no es capaz de capturar las componentes periódicas observadas, para resolver esto, denote el polinomio encontrado en la parte anterior como  $f^{pol}$  y modele la señal como  $f^{pol}$  más una componente sinusoidal modulada por una exponencial, es decir:

$$y = f_{\theta}(x) = f^{pol} + \theta_1 \sin(\theta_2 x + \theta_3) e^{\theta_4 x} + \eta, \quad \eta \sim \mathcal{N}(0, \sigma_\eta^2)$$

Solo ajuste los parámetros  $(\theta_{1:4})$  y el ruido  $\sigma_{\eta}^2$  del modelo mediante máxima verosimilitud, es decir, mantenga sin modificar la componente polinomial  $f_{pol}$  del inciso anterior.

Note que este modelo **no** es lineal en los parámetros por lo cual la solución no puede ser escrita de forma exacta. Para ello construya la función de verosimilitud y optimícela usando el método BFGS. Recuerde que no es necesario calcular analíticamente el gradiente de la función a optimizar dependiendo de la implementación de BFGS utilice.

Discuta la capacidad del modelo para predecir el conjunto de evaluación e interprete los parámetros del modelo.

**HINT:** Utilice 0.01 como condición inicial para  $\theta_4$ .

(iv) Como podrá notar, la 'forma de onda' de los datos no es puramente sinusoidal, por esta razón, denote la función encontrada en la parte anterior como  $f^{pol-sin}$  y agregue una segunda componente senoidal modulada por una exponencial, es decir:

$$y = f_{\theta}(x) = f^{pol-sin} + \theta_5 \sin(\theta_6 x + \theta_7) e^{\theta_8 x} + \eta, \quad \eta \sim \mathcal{N}(0, \sigma_n^2)$$

Recuerde los parámetros de  $f^{pol-sin}$  son fijos y encuentre los nuevos parámetros  $\theta_{5:8}$  y  $\sigma_{\eta}^2$  usando máxima verosimilitud y BFGS. Evalúe su solución en la prediciendo el 25% restante de los datos.

**HINT:** Utilice 0.01 como condición inicial para  $\theta_8$ .

Presente sus resultados y discuta el método en que los obtuvo, en particular, explique el rol de cada una de las componentes del modelo final, es decir el modelo que considera la parte polinomial y ambas componentes sinusoidales. Además, comente sobre los distintos estimados de la varianza del ruido  $\sigma_n^2$  en cada etapa.

¿Habría sido posible entrenar el modelo final de una vez? Evalúe los modelos ajustados en función de su verosimilitud y del error de predicción en el conjunto de test.

## P2. Proyecto curso

- (i) Forme grupos de a lo más **3** personas (Si es de postgrado, máximo 1). Como grupo elijan una propuesta de proyecto y descríbalo.
- (ii) Sobre el proyecto que piensa realizar, muestre y describa los datos que piensa utilizar.